

LLM 应用-实体关系识别

如今 LLM(大语言模型)的问答与生成能力已被大家所熟知，很多用户已经亲身体会到了 LLM 为工作、生活带来的变革。其实，作为 NLP(自然语言处理)的集大成者，LLM 能为我们提供的能力不限于此。其基本胜任传统 NLP 技术所能承担的所有任务。如：分词、语义识别、命名实体识别、实体关系识别等。其中，命名实体识别、实体关系识别在 NLP 任务中属于难度较大的任务。传统的 NLP 方案，一般针对不同的业务领域都要进行专门的模型训练，从而提高识别率，但真实效果也往往不尽如人意。这也使得需要以这类技术为基础的业务，发展速度受到了一定的限制。

一个比较常见的实体关系识别场景是构建行业知识图谱。在构建知识图谱时，需要从海量的行业知识文档中提取有效的实体及其实体关系，而后进行数据预处理、实体对齐等操作。在今年以 OpenAI 为代表的 LLM 席卷全球前，笔者尝试了很多开源技术来进行实体关系的识别，发现中文环境下，百度的 Paddle 所展示出的效果最好的。但其能够识别的文本篇幅及质量仍让人感到些许遗憾。直到 LLM 出现在笔者视野里，笔者开始尝试使用 LLM 来完成实体关系的识别，结果令人感到兴奋。

测试时，我们使用了如下的一段文字：

```
帮我抽取“####”后内容中的黑客组织及其账号，并输出为json格式
####
```

```
ATW 组织发布的“ATW-对华战争”帖
2021 年 10 月，ATW 组织开始频繁活动，不断在电报群组（https://t.me/s/ATW2022，
Email:AgainstTheWest@riseup.net，备份 Email:apt49@riseup.net）、推特
（@_AgainstTheWest，https://mobile.twitter.com/_AgainstTheWest）、Breadched
（账号：AgainstTheWest）等境外社交平台开设新账号，扩大宣传途径，并表现出较明
显的亲美西方政治倾向，多次声明“攻击目标是俄罗斯、白俄罗斯和中国、伊朗、朝
鲜”、“愿意与美国、欧盟政府共享所有文件”、“愿受雇于相关机构”。
```

文本中的第一句是我们给 LLM 输入的提示(Prompt)信息，要求其提取后续内容中的黑客组织及其账号，然后将结果以 Json 格式输出。而“####”后的内容为一小段文字，是 LLM 要处理的目标文本。下面让我们来看一看当把这段文字交给 GPT，它的输出表现吧。

以下是使用 GPT 3.5(Old)时，其模型的结果输出：

```
{
  "组织名称": "ATW",
  "账号": [{
    "平台": "电报",
    "链接": "https://t.me/s/ATW2022"
  }, {
    "平台": "Email",
    "地址": "AgainstTheWest@riseup.net"
  }]
}
```

```

    },{
      "平台": "备份Email",
      "地址": "apt49@riseup.net"
    },{
      "平台": "推特",
      "账号": "@_AgainstTheWest",
      "链接": "https://mobile.twitter.com/_AgainstTheWest"
    },{
      "平台": "Breadched",
      "账号": "AgainstTheWest"
    }
  ]
}

```

当看到这个结果时，令人眼前一亮。其不但分析出了黑客组织及其相关账号，还为每个账号进行了平台划分。一定程度上超出了当时给其写提示时的期望输出。结果的条理性超过了一般人类的总结水平。而在这个基础上再使用程序进行自动化处理，构建知识图谱就变的方便很多了。

笔者发现，GPT 3.5 升级以后，同样的输入只能获得如下的输出了

```

{
  "黑客组织": "ATW",
  "账号信息": {
    "电报群组": "https://t.me/s/ATW2022",
    "电子邮箱": "AgainstTheWest@riseup.net",
    "备用电子邮箱": "apt49@riseup.net",
    "推特账号": "@_AgainstTheWest",
    "推特链接": "https://mobile.twitter.com/_AgainstTheWest",
    "Breadched账号": "AgainstTheWest"
  }
}

```

这里的输出省去了对平台的扩展整理，但更加符合输入的提示。虽无惊喜，但更加稳定。

为了获得类似升级前的效果，我们修改提示的描述如下：

帮我抽取“####”后内容中的黑客组织及其账号与账号平台，并输出为json格式

可以获得如下输出：

```

{
  "黑客组织": "ATW",
  "账号": [
    {"平台": "电报群组", "用户名/链接": "https://t.me/s/ATW2022"},
    {"平台": "Email", "用户名/链接": "AgainstTheWest@riseup.net"},
    {"平台": "备份 Email", "用户名/链接": "apt49@riseup.net"},
    {"平台": "推特", "用户名/链接": "@_AgainstTheWest, https://mobile.twitter.com/_AgainstTheWest"},
    {"平台": "Breadched", "用户名/链接": "AgainstTheWest"}
  ]
}

```

从输出的信息可以看到，我们希望获得的要素信息基本都被识别出来了，只是在输出格式上有一定差别。我们可以通过编写处理程序解析这个 Json 数据，获取有效的实体关系信息。

但这种方式的灵活度稍差，需要根据 LLM 的输出结果不断进行调整适配。一种更好的办法是，在提示中给出 Json 格式的输出样例，以确保 LLM 按照指定的格式输出结果，方便后续的程序统一处理，更加简单、方便。（注：以上两种 GPT 3.5 版本的实验是通过 [TheB.AI](#) 网站完成的。如果使用 OpenAI 提供的 ChatGPT，由于其在获得提示后更倾向于输出 Python 脚本，所以在提示的最后需额外加入”不需要给出代码”，以确保其能够正常输出 Json 结构的数据。）

从目前的实验结果看，使用 LLM 进行实体关系的识别，较之前的技术，有了很大程度的提升。这种提升能大幅促进知识图谱等应用系统的构建效率及准确性。但在使用 LLM 的这种技术时，需要注意，不同的 LLM 在相同的提示和输入下，返回的信息会有不同。使用者需要选取合适的 LLM 并尝试不同的 Prompt，确保 LLM 的结果符合预期。